

Predicción de variables meteorológicas usando una PINN basada en las ecuaciones de Navier-Stokes

Sebastián Alejandro Gómez Ardila

Director de tesis: Dr. Diego Roldan

Universidad Central
Facultad de Ingeniería y Ciencias Básicas
Maestría en Analítica de Datos

2026

Contenido

- 1 Introducción
- 2 Planteamiento del Problema
- 3 Objetivos
- 4 Antecedentes
- 5 Marco Teórico
- 6 Metodología
- 7 Resultados
- 8 Discusión
- 9 Conclusiones

El desafío de la predicción atmosférica

La atmósfera es un sistema caótico gobernado por ecuaciones no lineales, donde pequeñas variaciones generan divergencias significativas (*efecto mariposa*).

- Nuevas fuentes de datos masivos: satélites, boyas, radares (ERA5, GOES)
- Limitación: métodos tradicionales requieren alto costo computacional
- Oportunidad: Redes Neuronales Físicamente Informadas (PINNs)

Planteamiento del Problema

El problema en la región Caribe


18 estaciones meteorológicas distribuidas en $404,7 \text{ km} \times 252,2 \text{ km}$

Densidad: 1,8 estaciones por $10.000 \text{ km}^2 \Rightarrow$ insuficiente

- Datos dispersos no describen el estado continuo
- Vacíos de información en zonas sin instrumentación
- Necesidad de estimar presión y viento

Planteamiento del Problema: Distribución de Estaciones

Estaciones meteorológicas — Caribe de Colombia
Diciembre 2025 · Datos Abiertos Colombia



Pregunta central

¿Cómo construir un modelo basado en PINNs que, a partir de registros meteorológicos dispersos y de las ecuaciones de Navier-Stokes, permita estimar la presión y las componentes del viento sobre una malla espacio-temporal en puntos donde no existen estaciones de medición?

Objetivos

Objetivo General

Desarrollar una PINN basada en ecuaciones de Navier-Stokes y registros de estaciones meteorológicas para estimar presión y componentes del viento sobre una malla espacio-temporal en el litoral Caribe.

Objetivos Específicos

- 1 Organizar y preprocesar datos de estaciones del IDEAM (diciembre 2025)
- 2 Diseñar una PINN que incorpore restricciones de N-S en su función de pérdida
- 3 Evaluar desempeño mediante métricas estándar ($RMSE$, MAE , R^2) en datos de prueba

Antecedentes: Métodos Tradicionales

Modelos Numéricos (NWP)

Resuelven Navier-Stokes en mallas de alta resolución (~ 9 km).

- Costo: 2.5 millones horas CPU/día (ECMWF)
- Ventana: predicción ≈ 10 días (sensibilidad caótica)
- Limitación: necesita condiciones iniciales altamente precisas

Métodos Estadísticos

ARIMA, Procesos Gaussianos

- Eficaces a corto plazo (< 72 horas)
- Desconectados de física fundamental
- Fallan ante eventos extremos sin precedentes

Antecedentes: Enfoques Modernos

Machine Learning Convencional (GraphCast, FourCastNet)

- Rápidos: predicciones en minutos (vs. horas en NWP)
- Entrenados con décadas de datos ERA5
- Inconsistencias físicas: $\sim 5\%$ violación de energía
- Caja negra: imposible explicabilidad física

Redes Neuronales Informadas por Física (PINNs)

Paradigma híbrido: celeridad del ML + rigor de EDP

- 30 % más precisión que NWP en casos críticos
- Garantiza coherencia física
- Requiere menos datos (conocimiento físico como regularizador)

Marco Teórico: Ecuaciones de Navier-Stokes

Conservación de momento y continuidad en fluidos viscosos:

$$\rho \left(\frac{\partial \mathbf{u}}{\partial t} + \mathbf{u} \cdot \nabla \mathbf{u} \right) = -\nabla p + \mu \nabla^2 \mathbf{u} + \mathbf{f}$$
$$\nabla \cdot \mathbf{u} = 0$$

Donde: $\mathbf{u}$ = velocidad, p = presión, ρ = densidad, $\mathbf{f}$ = fuerzas externas (Coriolis).

Reto clave

El término convectivo ($\mathbf{u} \cdot \nabla \mathbf{u}$) introduce **no linealidad** que dificulta soluciones analíticas.

Las PINNs codifican ecuaciones diferenciales parciales directamente en su función de pérdida, garantizando que las predicciones respeten leyes físicas.

- Combinan datos observados con restricciones físicas
- No requieren volúmenes masivos de datos
- Conocimiento físico actúa como regularizador
- 30 % más precisión que NWP en casos de intensificación rápida

Formulación: Función de Pérdida Híbrida

Una PINN minimiza una función de pérdida que combina dos términos:

$$\mathcal{L}_{total} = \mathcal{L}_{data} + \lambda \mathcal{L}_{physics}$$

Término de datos

$$\mathcal{L}_{data} = \frac{1}{N} \sum_{i=1}^N \|\hat{u}(x_i, y_i, t_i) - u^{obs}(x_i, y_i, t_i)\|^2$$

Diferencia entre predicciones y observaciones de estaciones.

Término físico

$$\mathcal{L}_{physics} = \frac{1}{M} \sum_{j=1}^M \|\text{NS}_{residual}(x_j, y_j, t_j)\|^2$$

Residual de Navier-Stokes en malla de colocación (garantiza coherencia física).

Hiperparámetro crítico

λ = peso del término físico (barrido: $\lambda \in \{1, 3, 5, 10\}$)

Metodología: Datos y Dominio

Datos de entrada

Estaciones meteorológicas IDEAM, región Caribe, diciembre 2025

Variables: Lat/Long, tiempo, velocidad/dirección viento, presión, temperatura

Volumen: 16.368 registros horarios de 22 estaciones (18 validadas)

Dominio espacial

Latitud	7,475° N a 11,115° N
Longitud	76,224° O a 73,926° O
Extensión N-S	404,7 km
Extensión E-O	252,2 km

Estructura de la red neuronal

- **12 capas** con **1.200 neuronas** cada una
- Capa personalizada `GammaBiasLayer`: Weight Normalization desacoplada
- Parámetros entrenables: $\approx 15,89$ millones
- Entrada: (x, y, t) normalizado — Salida: (u_x, u_y, p) adimensional

Diseño y regularización

- **8 capas Tanh** (no linealidad) + **4 capas Lineales** (regularización implícita)
- Pérdida física evaluada en 226.176 puntos de colocación (regularizador)
- Ratio parámetros/datos: 1.186:1 para 13.392 puntos de entrenamiento

Configuración experimental

- Epochs: 2.000
- Learning rate: 1×10^{-4} con ReduceLROnPlateau
- Datos por estación: 300 registros (5.400 totales)
- Malla de colocación: 304 puntos ($R = 0,1$) o 44 puntos ($R = 0,4$)

Variables barridas

Resolución de malla $R \in \{0,1, 0,4\}$

Peso físico $\lambda \in \{1, 3, 5, 10\}$

Resultados: Desempeño Comparativo

Mejor modelo: todos_R01_L5

Resolución $R = 0,1$, $\lambda = 5$, datos completos (~ 744 reg/est)



Modelo	Loss	MSE_{u_x}	MSE_{u_y}	MSE_p	$\mathcal{R}_{NS}$
todos_R01_L5	0,9261	0,4633	0,4347	1,3688	0,01273
300xest_R01_L5	1,1207	0,4689	0,4647	1,6220	0,03682
300xest_R04_L1	1,0575	0,5059	0,5085	1,5720	0,24141
300xest_R01_L1	1,1380	0,4806	0,4756	1,6477	0,20107
300xest_R04_L10	1,0859	0,5220	0,5224	1,6185	0,02242
300xest_R01_L10	1,1624	0,4919	0,4966	1,6906	0,02318

- Error observacional promedio: **0,7556** (mejor entre todos)
- Residual Navier-Stokes: **0,01273** (máxima coherencia física)

Resultados: Análisis de Convergencia

Ranking por error observacional promedio

- 1 (1) todos_R01_L5: 0,7556 (coherencia física: 0,01273)
- 2 (2) 300xest_R01_L5: 0,8187 (coherencia física: 0,03682)
- 3 (3) 300xest_R01_L10: 0,8267 (coherencia física: 0,02318)



Resultados: Validación Fuera de Muestra

Tabla 5.8: Comparación de métricas (train vs. test temporal)

Métrica	Entrenamiento (días 1–20)	Prueba (días 21–31)	Diferencia
MSE_{u_x}	0,4633	0,4422	−4,5 %
MSE_{u_y}	0,4347	0,4248	−2,3 %
MSE_p	1,3688	3,9116	+185,8 %
$\mathcal{R}_{NS}$	0,01273	0,03640	+186,0 %

Lectura técnica

- Generalización favorable en viento: u_x y u_y se mantienen estables en prueba.
- Brecha crítica en presión y residual físico: evidencia de dificultad de extrapolación temporal.
- Mensaje clave: buena robustez para velocidad, cautela para presión fuera del período de entrenamiento.

Tabla 5.4: Comparación de resoluciones ($\overline{MSE}_{obs}$)

λ	R=0,1	R=0,4	Δ (R0,4 - R0,1)	Mejor R
1	0,86796	0,86216	-0,0058	0,4
3	1,24982	1,02208	-0,2277	0,4
5	0,85185	1,32126	+0,4694	0,1
10	0,89305	0,88765	-0,0054	0,4

Lectura técnica

- R=0,4 domina en $\lambda \in \{1, 3, 10\}$.
- El único caso donde la malla fina supera claramente es $\lambda = 5$.
- Decisión final: R=0,1 con $\lambda = 5$ por mejor equilibrio en el régimen óptimo.

Resultados: Efecto de la Restricción Suave de Rango

Tabla 5.6: Comparación de pérdida final (época 2.000)

Experimento	Registros totales	Mecanismo de rango	Loss final
300xest_R01_L5	5.400	No	1,117
todos_R01_L5	13.392	No	0,926
todosreg_R01_L5_rangeL05	13.392	Sí	0,638



Lectura técnica (sección 5.4.6)

- Manteniendo $R = 0,1^\circ$ y $\lambda = 5$, activar rango reduce la loss final de 0,926 a 0,638.
- Reducción relativa frente al modelo equivalente sin rango: **-31,1 %**.
- La restricción de rango regulariza la optimización y mejora la plausibilidad del campo previo a visualizar u y v .

Resultados: Campos Predichos de Velocidad

Interpretación física de la mejor corrida con restricción de rango

La configuración `todosreg_R01_L5_rangeL05` no solo reduce la pérdida total, sino que genera campos espaciales continuos y físicamente plausibles para las componentes horizontales del viento sobre el dominio Caribe.



Logros principales

- Integración exitosa de N-S con datos dispersos: $\mathcal{R}_{NS} = 0,01273$
- Menor dependencia de datos: 300 muestras por estación vs. millones de datos en ML convencional
- Coherencia física garantizada en extrapolación

Ventaja vs. métodos alternativos

vs. NWP: 30 % menor costo computacional, no requiere condiciones iniciales altamente precisas

vs. Estadísticos: Respeta leyes físicas, válido en eventos extremos

vs. ML puro: Errores físicos reducidos, generalización mejorada

Contribuciones principales

- Demostración exitosa de PINNs en reconstrucción meteorológica a escala local
- Metodología reproducible y escalable para regiones con datos dispersos
- Validación de coherencia física ($\mathcal{R}_{NS} = 0,01273$) en modelos híbridos

Logro de objetivos

[Org] Organización y preprocesamiento: 16.368 registros de 18 estaciones

[Diseño] Diseño e implementación: PINN con restricciones N-S integradas

[Eval] Evaluación: 9 experimentos con métricas reproducibles

Extensiones inmediatas

- **Predicción temporal**: transición de interpolación a pronóstico ($t + \Delta t$)
- **Variables adicionales**: humedad relativa, radiación solar
- **Análisis de sensibilidad** a resolución de malla (R más fina)

Aplicaciones emergentes

- **Extensión a otras regiones** oceanográficas (Pacífico colombiano, cuencas andinas)
- **Acoplamiento con modelos** de dispersión de contaminantes
- **Integración en sistemas** operativos de monitoreo ambiental

Gracias